

MeetingAssistant 会议助手

CI passing

license Apache-2.0

实时会议 / 面试助手：一边流式转写对方的话，一边用 AI 生成你可以照着念的第一人称回答。Windows / macOS · 本地优先 · BYOK（自带 Key，没有账号系统、没有中间服务器）

Real-time meeting/interview assistant for Windows and macOS: streaming ASR captions of the other party plus first-person AI answers you can read aloud. Local-first, bring-your-own-key, no bot joins your meeting — it just listens to your system audio. 中文文档为主，English summary at the bottom.

📄 本文档有可离线分发的 PDF 版本：[README.pdf](#)（排版同上，适合打印或投屏阅读）。

🌟 核心功能

- **实时流式转写**：通过系统回环音频采集对方声音，**不碰会议软件**——Teams、Zoom、飞书、腾讯会议、任意视频都能用，不需要机器人入会、不需要抓包。
- **第一人称 AI 回答**：在对方任意一句上点 ⚡ 答，提词卡流式生成可直接照着念的回答；打开 **持续答** 后，只有真的在提问才会自动触发——明显的寒暄与流程安排（「把这个链接发我一下」）由本地启发式免费挡掉，拿不准的一句才花一次极小的分类调用判断，判定超时或失败一律回退成“照答”。
- 🖨️ **做题模式（在线测评/笔试）**：标题栏 **做题** 打开一个小窗悬浮面板，它对录屏 / 共享 / 截图不可见（强制开启，无开关）。框选屏幕上的题目 → 读题 → **先查你本机的题库**：命中就直接把库里的答案和字母亮出来（约 1ms，完全离线），没命中才交给 AI，AI 也不确定时再按你的开关联网检索。四种题型各自绑定不同目录、各有答法：
 - **行测/申论、代码/技术**：绑定本地题库目录（递归读取 .md/.txt/.json/.csv/.pdf）。真题包常见的**「题目卷 + 答案卷」成对 PDF**（...-学生版.pdf / ...-答案版.pdf，答案卷里是 N.【答案】D。解析：... 或 1~5 BACDB）会按（节, 题号）自动配对——**两卷的节名对不上时宁可不配**，绝不把英语的答案配到数量关系上；屏幕把选项打乱时，答案按**选项文字重新锚定**回字母。
 - **性格/心理测评**：先按“招聘方看重什么”生成一份**固定人设**（可用网络检索生成，也可手填），随后整场测评都照这份人设作答，并显式规避“全部非常符合”这类会触发装好/测谎校验的答法，反向表述的题自动把方向调转。
 - **精度优先的取舍**：只有「原题级命中 + 客观题 + 能锚定到屏幕选项」才会免模型直答；相近题会同时列出来让你确认；库里没有的题一律走 AI（并按需联网），不会硬凑一个答案。成堆下载来的题库必然互相重复：同一道题自动合并（保留解析最全的那份），**不同文件答案互相矛盾的题会被标成“答案不一致”而不是猜一个**；题干只是一句通用指令（如图形推理的「选择最合适的一项填入问号处」）时也不直答——真正的题在图里，文字认不出来。

- **可以只绑一个总目录**：四个题型都指向同一个 题库 根目录也可以（本机是纯字面索引，多出的内容只会让候选变多，不影响命中速度）。代价是别的题型里的长篇资料可能作为「相近题」被列出来让你确认——它们永远不会被当成原题直接作答。
- **读屏有两条路**：装 `npm i tesseract.js`（约 2MB 语言包，全离线）则截图先在本机识别文字，读不到题再交给视觉模型；没装就需要一个**支持图片的 API Key**（Gemini / 智谱 / Groq / 百炼 / MiMo / Ollama 等）。两者都没有时框选会直接说明缺什么，此时可用「题库自检」右侧的**作答这题**：把题干粘贴进去，同样走 题库 → AI → 网络 的完整链路。
- **提词主视图 + 转录气泡**：左栏是一条**转录导轨**——每句一个**聊天气泡**、说话人分色、整句在泡内换行，实时 `_partial_` 钉在底部； **复制 / 译 / ⚡ 答** 在悬停（或键盘 Tab 聚焦）到那句时才出现。导轨右缘的细条可**拖拽调宽**（10%–50%，默认 16%，重启保留）；点右上角  才展开完整转录面板（框选提问、清屏在那里），**点泡泡本身不会放大**。提词卡的历史回答收成一行「历史回答 · N」， 展开 /  收起，**默认收起**并把空间留给当前回答（状态重启保留）。
- **回答风格（会议中随时改）**：标题栏  一次弹出**内容量**（精简 15-25 秒 / 标准 30-60 秒 / 详尽 90-150 秒）、**专业度**（口语 / 职场 / 技术）与**应答人设**三组选择，改完**下一条回答就生效**。默认「标准 + 职场」，输出长度与上一版一致。
- **应答人设库与提示词进阶**：设置 → 通用 → 高级设置 → **应答人设库** 里预先写好最多 12 套「我是谁、我怎么说话」（可点**从简历/JD 生成初稿**，草稿要你确认保存），会前用  选一套；同处的**提示词进阶**直接编辑系统提示词的三层（基础人设模板 / 回答风格指令 / 自定义追加指令），灰字即内置原文、留空即用，并给出**最终拼接预览**的字数。这些层都落在**可缓存的稳定前缀**上：什么都不设置时，发给模型的提示词与上一版**逐字节相同**。
- **右下角延迟 HUD**：状态栏右侧显示「话落→出字」端到端延迟（末条 / p50 / p95）、首字延迟与推理耗时；悬停每项都有解释，用于判断慢在防抖门控、检索还是模型本身。
- **手机显示（局域网）**：设置里打开**手机显示**后，本机变成一个只在局域网里说话的网页服务，**手机浏览器扫码即看**——左边实时转写、上面大字显示当前答案（流式逐字、公式照常排版）。它挂在主进程的事件源上，**不经过界面窗口**，所以电脑这边可以彻底隐身、不开任何窗口，屏幕上没有任何东西会被共享或拍到。同时它也接管「**后台截屏答题**」：按下截屏热键 → 拍屏 → 读题 → **先查本机题库** → 答案直接出现在手机上，全程不用回头看电脑。延迟在这条链路上是**显式量**：手机上每次 ping/pong 校准两机时钟差后显示真实端到端毫秒数，设置面板显示线路延迟与「因手机跟不上而丢弃」的计数。
 - 配对走「**6 位配对码** → **长期令牌**」：配对码**只显示在这台电脑上**，绝不回传给发起请求的设备，所以同一局域网里别人无法自助连进来；令牌存在手机本地，之后免配对直连。
 - **在手机上实时改设置**：连上后手机页面顶部多出一条**控制**栏——远程开关**转录与持续答**、切换**回答内容量 / 专业度**、**输入问题**（纯文本）、回看本次会议**历史回答**。**颜色即电脑真实状态**，点了**不等于生效**（1.5 秒没等到回状态标「未确认」），电脑侧不弹任何提示。默认开启，可在 设置 → 通用 → 手机显示 → **允许手机远程控制** 整体关掉或按六项逐个授权。
 - 默认 HTTPS（自签证书）：一是加密局域网这一段，二是手机浏览器的**屏幕常亮 API 只在安全上下文存在**，明文 http 下手机亮到一半就息屏。手机首次访问会提示证书不受信任——**只有报 `ERR_CERT_AUTHORITY_INVALID` 时才有「高级 → 继续前往」可点**；连接窗里备了一颗「**改用 HTTP**」按钮，专治那些不提供绕过入口的安卓浏览器（代价是手机不能保持常亮，按钮旁写明了）。也可以下载 `/server.crt` 装进信任列表彻底消除警告。自签证书**挡得住被动嗅探，挡不住主动中间人**，仅限可信局域网。
 - **Windows 防火墙**：第一次监听端口时系统会弹窗，请允许「专用网络」；拒绝后手机会一直连不上而电脑侧毫无异常。

- **回答可控：** 答:中 / 答:EN 切换回答语言； 纯文本 / 多模态 在文本大模型与视觉模型（可截图提问）之间切换。
- **公式与排版正常显示：** 回答里的 $\$...\$$ / $\$...\$$ / $\backslash(...\backslash)$ / $\backslash[...\backslash]$ 由 KaTeX 排版（含 $\$ \dots \$$ 这种两端带空格的写法），****加粗****、***斜体***、``代码``、**###** 小标题 也直接渲染，不再把 markdown 原样吐在屏幕上。
- **贴合你的阅历：** 提词卡上  **简历** /  **JD** 导入资料（.md/.txt/.docx/.pdf/.pptx），本地解析、本地建立索引，只在提问时作为上下文发给大模型——资料本身不离开你的电脑。不同面试是不同的会话，各自绑定自己的资料与答案库。
- **导入看得见进度、失败有原因：** 设置 → 知识库 有 **导入文件...**（可多选）与 **导入文件夹...** 两颗按钮，导入过程按文件实时上报（导入中 12/37...），每个文件一行结果：已入库 / 未变化 / 已跳过 / 失败，并写明原因（格式不支持、抽不出文字=扫描版或图片型 PDF、解析失败、索引未就绪未写入）。**重复导入内容没变的文件会被跳过**（先比 mtime+大小，再比正文哈希），不再是全量重建。
- **导入后自动做「节摘要」：** 每份入库文档按节切开（PPTX 按幻灯片、带标题的按标题、其余按长度），每节存一条**抽取式**短摘要进索引——用来回答“这套方案的评测方法是什么”这类跨节、文档级的问题（这类问题在 300 字的语块里永远匹配不到）。每篇最多 40 节、单次检索最多带 2 条，避免摘要挤掉原文；**全在本机、不调模型、零费用**。PPTX 的**演讲备注与表格**也会被抽取。
- **回答默认不再请求「思考」：** 设置 → 模型 → 思考强度 的默认值是**关闭**，即支持思考模式的模型不再在你没要求时偷偷推理（首字延迟与 token 都要付钱）。想要思考回答就在下拉框选 低 / 中 / 高；选「跟随默认」则完全不发送思考参数。
- **提前准备的答案优先亮出来：** 资料或笔记里写成 问: ... 答: ... / Q: ... A: ... / **【问题】...【回答】...** 的段落会被自动识别成问答对并按「问题」建索引。面试官的问题命中时，提词卡**先原样显示你准备的答案**（本地检索，几十毫秒内可见），再由 AI 在其基础上充实成可以直接念的完整回答——这条路径完全离线。
- **知识库没有答案才联网：** 只有本地知识库毫无命中时，才会把问题发给你自己配置的搜索引擎（Tavily / Brave / SerpAPI, BYOK, 默认关闭），检索结果作为回答依据并附上来源；一次检索最多等 2.5 秒，超时即放弃、绝不影响出词。
- **会话可删除：** 提词卡上  删除整场对话（对话、转录、已索引的简历/JD 与其准备答案一并清除，有二次确认）。
- **本地优先：** 默认语音识别是本地 FunASR，音频**不出本机**；云端方案（阿里云百炼等）只在你自己配置后才会发送音频。
- **隐身模式：** **隐身开/关** 让窗口对录屏 / 屏幕共享 / 截图不可见（Windows 有效，macOS 尽力而为），窗口默认也不出现在任务栏——隐藏后用快捷键（默认 Control+B）或系统托盘找回。
- **BYOK 隐私边界：** API Key 用系统加密存储在本机；没有账号、没有服务器、不代收任何费用，费用直接付给服务商。
- **为普通用户设计：** 首次启动 5 步配置向导（含方案卡片、图文 Key 教程、声音检测、**真实连接测试**，14 个统一错误代码）；状态栏芯片一眼看清转写 / AI / 声音是否可用；诊断报告不含 Key、转写与简历内容，可直接贴进 issue。
- **中英双语界面：** 向导里选择语言，应用启动即用该语言；系统托盘提供「开始 / 停止转写 / 新建会话 / 设置 / 服务状态 / 帮助与教程 / 检查更新 / 退出」。

界面与操作详解

主界面就三块：**标题栏**（开关与模式）、左侧**转录导轨**（对方说了什么）、右侧**提词卡**（你可以怎么答）。下面是每个功能从点击到出结果的完整操作路径。

1. 实时转写：开始 / 停止 / 调宽 / 展开

1. 让电脑播放有人说话的内容（会议、视频、播客都行）——采集的是**系统回环音频**，不需要麦克风、不需要会议软件配合。
2. 点标题栏 **▶ 开始**，转录导轨开始逐句出字（每句一个**聊天气泡**，说话人分色、整句在泡内换行，实时识别中的半句钉在底部显示 `_partial`）。
3. 点标题栏 **|| 停止**（或托盘菜单「停止转写」）结束采集。
4. 导轨右缘有一根细条，**按住拖拽**即可调宽（10%–50%，默认 16%，重启后保留）。
5. 鼠标**悬停**（或键盘 Tab 聚焦）到某个泡泡上，右下角浮出 **📄 复制 / 译 / ⚡ 答** 三个按钮——点 **⚡ 答** 就地为这句生成回答，点 **📄** 把原文送进剪贴板，点 **译** 在该句下面内联显示对照译文（译文不进对话上下文）。
6. 想看整屏的完整转录面板（框选提问、清屏都在里面）：点导轨右上角的 **↗**，面板以覆盖层弹出，点 **×** 回到导轨。**点泡泡本身不会放大**，布局也不会被顶掉。
7. 想把自己的发言也单独转写：打开标题栏 **🎤 麦克风**（建议戴耳机，避免扬声器回声被二次采集）。

2. AI 回答：⚡ 答 / 持续答 / 回答语言 / 双通道

- **手动答**：把鼠标移到（或 Tab 聚焦到）导轨里对方那个泡泡上，点浮出的 **⚡ 答**，提词卡流式生成一段第一人称、可直接照着念的回答；整屏转录面板（**↗**）里也照样能逐句作答。
- **持续答**：打开标题栏 **持续答**，AI 自动接话。门控是三层：明显的寒暄与流程安排（「把这个链接发我一下」）由本地启发式免费挡掉；拿不准的一句才花一次极小的分类调用判断；**判定超时或失败一律回退成「照答」**，宁可多答不漏答。
- **回答风格**：标题栏 **⌵** 一次弹出三组选择——**内容量**（精简 / 标准 / 详尽）、**专业度**（口语 / 职场 / 技术）、**应答人设**。改完**下一条回答就生效**，不用重启、不用回设置页。每档都标了念完要多久（约 15-25 / 30-60 / 90-150 秒），默认「标准 + 职场」。人设先在 **设置** → **通用** → **高级设置** → **应答人设库** 写好（或点 **从简历/JD 生成初稿**，草稿填进输入框、你改完点保存才生效），再回这里启用。
- **思考强度**：默认**关闭**——回答不该为你看不见的推理付首字延迟和 token。要开：**设置** → **模型** → **思考强度** 选 **低 / 中 / 高**（只对支持思考模式的模型出现）；**跟随默认** 表示一个思考参数都不发。
- **历史回答可折叠**：提词卡上方一行 **历史回答 · N**，**▶ 展开回看**、**▼ 收起**把纵向空间留给当前回答；默认收起，展开与否重启后保留。点任一旧回答即进入**回看模式**（顶部提示「正在回看旧回答」），点 **回到最新** 继续跟流。
- **回答语言**：标题栏 **答:中 / 答:EN** 切换。此外，在任意一句上选择「翻译」可把该句转录内联翻译成另一语言。
- **文本 / 视觉双通道**：标题栏 **纯文本 / 多模态** 切换回答用的模型。多模态下可以**截图提问**（把屏幕上的内容作为图片发给视觉模型）。
- **删除会话**：提词卡 **🗑** 一次删掉整场对话（对话、转录、该会话已索引的简历/JD 与准备答案全部清除），有二次确认。不同面试建不同会话（托盘「新建会话」），资料与答案库按会话隔离。

3. 简历 / JD 知识库：导入 → 准备答案 → 命中

- 1. 提词卡上点 简历 或 JD，选本地文件（.md/.txt/.docx/.pdf/.pptx）。解析与索引全部在本机完成，资料本身不出电脑，只有在提问时才作为上下文发给你配置的大模型。
- 2. 批量资料走 设置 → 知识库：导入文件...（一次可多选，一份 PDF 不必为它建目录）与 导入文件夹...（递归，跳过隐藏文件与不支持的扩展名）。只接受 .md/.markdown/.txt/.docx/.pdf/.pptx；面板下方常驻提示「旧版 .doc / .ppt 请先转成 .docx / .pptx」——那类 97-2003 老格式没有可靠的纯 JS 解析器，选了也会被记成 格式不支持 跳过，而不是把乱码写进索引。
- 3. 导入过程看得见：按文件实时上报进度（导入中 12/37...），每个文件一行结果——已入库 / 未变化 / 已跳过 / 失败，原因写明白：格式不支持、抽不出文字（扫描版/图片型）、解析失败（悬停看原始错误）、索引未就绪，未写入。重复导入内容没变的文件直接跳过（先比 mtime+大小，再比正文哈希），不解析、不重新嵌入、不动索引。
- 4. 导入后自动做本地节摘要：每份入库文档切成节（PPTX 按幻灯片、带标题的按标题层级、其余按长度分组），每节存一条抽取式短摘要进索引——用来回答"这套方案的评测方法是什么"这类跨节、文档级问题（300 字的语块永远匹配不到它们）。每篇最多 40 节、单次检索最多带 2 条摘要，避免摘要挤掉原文；全在本机完成、不调用模型、零费用。PPTX 的演讲备注与表格同样会被抽取，写在备注里的答案能被检索到。
- 5. 准备答案优先亮出：资料或笔记里写成 问：... 答：... / Q: ... A: ... / 【问题】...【回答】... 的段落会被自动识别成问答对、按「问题」建索引。面试官的问题命中时，提词卡先原样显示你准备的答案（本地检索，几十毫秒），再由 AI 在其基础上充实成可以直接念的完整回答——这条路径完全离线、不花一次网络请求。
- 6. 联网兜底：只有本地知识库毫无命中时，才会把问题发给你配置的搜索引擎（设置 → 视觉与搜索 → 网络检索兜底：Tavily / Brave / SerpAPI，各自带免费额度，默认关闭）。一次检索最多等 2.5 秒，超时即放弃、绝不影响出词；检索结果作为回答依据并附上来源。
- 7. 想先看看某个目录能被识别出多少条准备答案：npm run qa:inventory -- <目录>（干跑，不调模型）。

4. 做题模式（在线测评 / 笔试）

- 1. 点标题栏 做题，打开一个小窗悬浮面板——它对录屏 / 共享 / 截图强制不可见，没有开关可关。
- 2. 四个题型各绑定一个本地目录（设置内指定），先选对题型再开始：

题型	绑定内容	答法
行测 / 申论	.md/.txt/.json/.csv/.pdf 题库目录	原题命中直接给库里的答案与字母（≈1ms、离线）；真题包「学生版 + 答案版」成对 PDF 按 (节, 题号) 自动配对，节名对不上宁可不配
代码 / 技术	同上	同上；屏幕把选项打乱时，答案按选项文字重新锚定回字母
性格 / 心理测评	一份固定人设（可联网生成也可手填）	整场照人设作答；显式规避「全部非常符合」这类触发装好/测谎校验的答法；反向表述自动调转方向
其他	任意目录	同行测链路

3. **框选答题**：在小窗里拖框选中屏幕上的题目区域 → 读题（装了 `tesseract.js` 先本机 OCR，读不到再交视觉模型；两者都没有会直接说明缺什么）→ **先查本机题库**，命中即答；没命中才交 AI，AI 不确定时再按需联网。
4. 快捷键： `Ctrl+Shift+S` 整屏截屏答题 · `Ctrl+Alt+A` 答最新一句 · `Ctrl+Alt+S` 框选截屏答题。
5. 精度底线：只有「原题级命中 + 客观题 + 能锚定到屏幕选项」才免模型直答；相近题只列出来让你确认；题库里答案互相矛盾的题会标成「答案不一致」而不是猜一个；纯图形题（题干只是「选择最合适的一项」）不直答。
6. 没有视觉模型也没有 OCR 时：用小窗里 **作答这题**——把题干粘进去，同样走 题库 → AI → 网络 的完整链路。
7. 干跑验证题库： `npm run exam:selftest -- <题库目录> [题目...]`。

5. 手机显示（双屏提问）

完整 7 步配对流程见下文「 单屏 / 双屏」；这里补充操作细节：

- **入口**：标题栏 **双屏** 分段控件，或 设置 → 通用 → 手机显示 → 打开连接窗口。进入双屏时**自动打开持续答**，主窗自动隐藏并强制隐身。
- **手机上看到什么**：左边实时转写流，上方大字显示当前答案（流式逐字、公式照常排版）。每次 ping/pong 校准两机时钟差，所以手机上打印的毫秒数是真实端到端延迟；设置面板另有线路延迟与「因手机跟不上而丢弃」计数。
- **在手机上实时改设置**：连上后手机页面顶部多出一条 **控制** 栏——远程开/关 **转录** 与 **持续答**、切换 **回答内容** / **专业度**、**输入问题**、回看本次会议 **历史回答**。颜色即桌面真实状态，点了不等于生效（1.5 秒内没等到桌面回状态就标「未确认」），且**电脑侧不弹任何提示**。授权见 设置 → 通用 → 手机显示 → **允许手机远程控制**（默认开启，含六项逐项开关）。详见下文「在手机上实时改设置」。
- **免看电脑截屏答题**：连接窗口勾选「**截屏热键只送手机**」后按 `Ctrl+Shift+S` 或 `Ctrl+Alt+S` ——拍屏、读题、查题库、答案直出手机，电脑这边不弹任何窗。不勾选时 `Ctrl+Alt+S` 恢复常规行为（弹做题小窗等你拖框）。
- **常亮**：手机上必须点一次「**常亮**」（浏览器规定须用户点击才允许保持亮屏），且只在 https 下可用——这就是默认自签 HTTPS 的第二个理由。
- **证书**：想彻底消除警告，可从 `/server.crt` 下载证书装进手机信任列表。自签证书挡得住被动嗅探，挡不住主动中间人，**仅限可信局域网**。
- **隐私边界**：只有你主动开启后才监听端口；数据只在电脑与手机间直连，不经任何第三方；关开关即停。默认端口 **18765**。

6. 隐身、快捷键与托盘找回

- **隐身开/关**（标题栏）：窗口对录屏 / 屏幕共享 / 截图不可见（Windows 有效，macOS 尽力而为）。
- 主窗默认**不出现在任务栏**。点  隐藏后，找回窗口两条路：
 1. 按呼出快捷键（默认 `Control+B`，设置 → 通用 可改）；
 2. 点系统托盘 MeetingAssistant 图标（或右键菜单「显示窗口」）。第一次隐藏时有一次气泡提示。
- 托盘菜单全集：**开始 / 停止转写、新建会话、设置、服务状态、帮助与教程、检查更新、退出**。

7. 延迟 HUD：慢在哪一步，一眼看出

状态栏右侧常驻显示：「话落→出字」端到端延迟（末条 / p50 / p95）、首字延迟（LLM 第一个字）、推理耗时。鼠标悬停每一项都有解释。用途：判断慢在防抖门控、检索还是模型本身——p50 高是普遍慢，末条飙升是偶发卡顿。

8. 状态芯片、诊断报告与向导重开

- 状态栏芯片一眼看清**转写 / AI / 声音**是否可用，无需打开设置。
- 出问题先查应用内 **帮助与教程**（托盘或 设置 → 帮助与教程，离线可读），再查 [TROUBLESHOOTING.zh-CN.md](https://troubleshooting.zh-CN.md) 的 14 个错误代码表。
- 要提 issue：设置 → 通用 → **诊断信息**（或标题栏 ... 菜单）生成报告——不含 Key、转写与简历内容，仅复制到剪贴板、不落盘。
- 配置向导随时重开：⚙ 设置 → **重新运行配置向导**（主窗口保持运行，不会退出应用）。

9. 回答风格、应答人设与提示词进阶

会议中要改的是“怎么说”，不是“重配一遍模型”。三条入口各有分工：

- **标题栏 ⓘ 回答风格**（会中随手改）：三组选择——**内容量**（精简 / 标准 / 详尽）、**专业度**（口语 / 职场 / 技术）、**应答人设**。点一下即刻生效，**下一条回答就用新的**，不需要重启也不需要进设置页保存。每档标了念完要多久（约 15-25 / 30-60 / 90-150 秒）。默认「标准 + 职场」，与上一版的输出长度一致。
- **设置 → 通用 → 高级设置 → 应答人设库**：最多 12 套第一人称人设（每套正文 ≤ 2000 字），写“我是谁、我怎么说话、答题习惯”。两种写法：
 1. **手写**——自己填名称与正文，保存后用 ⓘ 启用；
 2. **从简历/JD 生成初稿**——先在提词卡上导入简历或 JD，点这颗按钮，模型按你的真实经历起草（约 10-30 秒），**初稿只是填进输入框，你改完点保存才入库**。人设只影响口吻、立场与详略，它不会替你编造简历里没有的经历；不启用任何人设即回到内置提词器口吻。
- **设置 → 通用 → 高级设置 → 提示词进阶**（Ⓢ 的直跳入口）：直接编辑系统提示词的三层——**基础人设模板 / 回答风格指令 / 自定义追加指令**。规则很简单：**输入框留空 = 用内置原文**，框里的灰字就是内置内容本身；每层可单独「恢复默认」，也可「全部恢复默认」。下面的**最终拼接预览**（只读）显示这一次真正发给模型的前缀全文与字数——注意它取当前会话的简历/JD/笔记，所以换一场会话字数就会变。
- **为什么这些改动不影响缓存**：以上所有层都拼在**稳定前缀**上（每次请求逐字节相同的部分），风格/人设变化只在该档位变化时改变字节；**装了新版本什么都不设置时，前缀与上一版逐字节相同**（有测试钉住），升级不会让既有回答风格漂移。
- **思考强度**：在 设置 → 模型，默认 **关闭**。支持思考模式的模型不再在你没要求时偷偷推理（那会同时抬高首字延迟与 token 费用）；要开就选 低 / 中 / 高，选 **跟随默认** 则一个思考参数都不发。手机端目前**不能**远程切换思考强度，只能远程切内容量与专业度。

界面预览



下面两张截图仍是 v1.0.0 的界面：转录栏还不是气泡、历史回答未折叠、标题栏还没有 。重拍待补，界面以应用实际显示为准。

- 双语实时演示：



- 完整演示视频：[MeetingAssistant-demo.mp4](#)

🔥 支持的 AI 服务 (BYOK)

能力	服务
流式语音识别（云端）	阿里云百炼实时识别（推荐）· MiMo（Beta）
分段语音识别	MiMo · 自定义 OpenAI 兼容服务
本地语音识别	FunASR（默认）· MOSS-Transcribe-Diarize（实验）· Whisper（离线兜底）
文本大模型	DeepSeek（推荐）· 智谱 · Groq · Gemini · Ollama（本地）· 自定义 OpenAI 兼容
多模态大模型	Gemini（默认经本地代理）· 自定义视觉模型

语音识别与 AI 回答通常各需要一个 Key，同一服务商可复用；「极简配置」方案只需注册一个平台（MiMo，语音识别与回答共用 1 个 Key）。Key 领取教程见 [API_KEYS.zh-CN.md](#)。

🔑 获取并填写 API Key (LLM / 语音识别)

先弄清楚要几个 Key

你要用的功能	需要的 Key	填在哪里
云端实时转写（推荐）	阿里云百炼 Key	向导第 3 步「语音识别」卡片；或 设置 → 语音识别
AI 回答（推荐）	DeepSeek Key	向导第 3 步「AI 回答」卡片；或 设置 → 模型
只要一个平台搞定两者	MiMo Key (Beta)	向导「极简配置」方案，勾选共用
截图问答 / 做题读题	任一 支持图片 的模型 Key (Gemini / 智谱 / Groq / MiMo / 百炼...)	设置 → 视觉与搜索 （国内连 Google 需填「视觉代理」，如 127.0.0.1:7897）
联网检索兜底（可选）	Tavily / Brave / SerpAPI Key	设置 → 视觉与搜索 → 网络检索兜底（默认关闭；开了没填 Key 会静默跳过联网）
本地转写 (FunASR/MOSS/Whisper) / 本地回答 (Ollama)	不需要云端 Key	见下文「本地语音识别」；Ollama 在 设置 → 模型 选本地方案，API Key 留空

语音识别与 AI 回答是**两个独立的服务商**，通常各需一个 Key；同一服务商（如 MiMo）可以复用同一个。

通用填写步骤（每个服务商都一样）

1. 到服务商控制台注册并**实名认证**（国内平台不实名建不了可用的 Key）。
2. 在「API Keys / API-KEY / API 密钥」页面**新建**一个 Key，起个好认的名字（例如 MeetingAssistant）。

3. **立刻复制**——绝大多数平台的 Key 只完整显示这一次，关窗后就再也看不到了（丢了就删掉重建，不影响账号）。
4. 回到 MeetingAssistant 粘贴：优先走**首次启动的 5 步配置向导第 3 步**（每张卡片带图文教程和「打开官方密钥页面」按钮）；错过向导则在 **设置** 对应 Tab 的输入框粘贴。也可以点「从剪贴板粘贴」。
5. 点 **「保存并测试连接」**。保存时自动去掉首尾空格、包裹的引号和 Bearer 前缀——多粘了这些也没关系。
6. 测试失败时卡片给出**归一化错误代码**与下一步建议（Key 错 / 余额不足 / 网络不通一眼分清），也可选「暂时保存并稍后重试」。完整代码表见 [TROUBLESHOOTING.zh-CN.md](https://github.com/zhong-zhi/TROUBLESHOOTING.zh-CN.md)。

各服务商要点

DeepSeek（推荐用于 AI 回答） — platform.deepseek.com：登录后进左侧「API keys」→「创建 API key」→ 复制。默认模型 `deepseek-flash`（首字最快、能读图），强推理档 `deepseek-v4-pro`（适合复盘不适合抢答）；**只接受这两个模型名**，旧名会报 400（应用会把你存过的旧名自动改成 `deepseek-flash`）。提示 `Insufficient Balance` 说明 Key 有效、只需充值。

阿里云百炼·中国大陆站（推荐用于实时转写） — bailian.console.aliyun.com：注册阿里云账号 → 开通「百炼」→ **实名认证** → 停留在**主账号默认业务空间**（子账号/自建空间可能没有实时语音识别权限）→ 右上角头像菜单「API-KEY」→「创建我的 API-KEY」→ 复制。默认模型 `fun-asr-realtime`。报 `Access denied` 多为未开通/未实名；报 `Model not found` 多半是账号属于国际站（国际站接入地址不同，本版本未提供预设，求稳定实时字幕请用大陆站账号）。

MiMo·小米（一个 Key 兼顾转写与回答，Beta） — platform.xiaomimimo.com：小米账号登录 → 控制台「API Keys」→ 新建 → 复制以 `sk-` 开头的 Key。同一 Key 同时填给语音识别与 AI 回答（极简配置方案）。注意它是**分段识别**，按整句返回、字幕跟随性弱于流式方案——这是方案特性，不是故障。

智谱 GLM（国内直连，有免费档） — open.bigmodel.cn：手机号登录（首次需注册+实名）→ 头像菜单「API 密钥」→「新建 API Key」→ 复制。`GLM-4-Flash` 免费额度充足、首字极快，适合低延迟兜底；`GLM-4.6` 是中文质量档，适合行为面与复杂问答；同一账号同一 Key。

Groq（英文编码题极速档） — console.groq.com：注册登录 →「API Keys」创建并复制（以 `gsk_` 开头）。服务器在海外，中国大陆网络通常需要本机代理。免费档有速率限制。

Google Gemini（可选，截图问答） — aistudio.google.com/app/apikey：Google 账号登录 →「Create API key」→ 选/建一个 Cloud 项目 → 复制，粘贴到 设置 → 视觉与搜索 的视觉 Key。国内通常无法直连：在「视觉代理」填本机代理地址（如 `127.0.0.1:7897`）。不想折腾代理可改用 MiMo 的 `mimo-v2.5` 做视觉，代理留空。截图问答是可选功能，跳过不影响转写和文字回答。

Ollama（完全本地，零 Key 零费用） — 本机安装并启动 ollama.com 客户端（默认监听 `127.0.0.1:11434`）→ 命令行 `ollama pull qwen2.5:7b` → 设置里 Base URL 填 `http://127.0.0.1:11434/v1`、模型名与拉取的一致、**API Key 留空**。速度取决于本机硬件，优势是回答完全不经过网络。测试失败先确认 Ollama 在跑（它默认只监听本机回环）。

自定义 OpenAI 兼容服务 — 准备一个以 `/v1` 结尾的 Base URL、模型名与 Key，填在 **设置** → **模型** → **高级设置**。出于安全考虑，应用只会用系统浏览器打开内置允许列表里的官方页面，自定义服务商的页面请自行访问。

Key 存在哪里、安全边界

- Key 用**系统凭据服务加密**后写入本机配置：Windows 用 DPAPI，macOS 用钥匙串。系统凭据服务不可用时，应用会在保存前弹警告（此时只能弱保护/混淆）。
- 解密后的 Key **只存在于主进程**，界面层永远拿不到，只能看到「已配置」与后 4 位。
- 删除 Key：设置里对应输入框旁「删除 Key」→「确认删除」→「保存」。
- **费用**：BYOK——Key 在服务商处创建、服务商直接向你计费；本应用没有账号、没有服务器、不代收、不分成、不加价。「测试连接」每次只发一个极小真实请求（1 个 token / 约 1.4 秒音频 / 一张 64×64 图），只在你点击时发生。
- Key 泄露 = 别人花你的额度：别贴进聊天记录、截图或公开仓库；泄露了去服务商控制台删掉重建即可，账号不受影响。

⚡ 快速开始（普通用户）

全程不需要安装 Node.js / Python，也不需要敲命令（本地转写才需要自备 Python，见下文）。

1. 从 [Releases 页面](#) 下载 MeetingAssistant-`<版本>-win-x64.exe`（安装版）或 `...-portable.exe`（免安装版）；建议核对旁边的 `.exe.sha256` 校验文件。
2. 启动后跟着 **5 步配置向导**走：欢迎 → 选择方案 → 配置服务（粘贴 Key 并「保存并测试连接」）→ 连接测试（检测电脑声音）→ 完成。
3. 播放会议 / 视频，点标题栏 ▶ **开始**，转录导轨开始出字（点导轨展开全部转录）。
4. 在对方那句上点 ⚡ **答** 生成回答；打开 **持续答** 自动接话；在提词卡导入 📄 **简历** / 📄 **JD** 让回答贴合你的经历。

Windows SmartScreen 会提示「已保护你的电脑」——安装包**未做代码签名**（不影响功能），确认后点「更多信息 → 仍要运行」即可。

详细走查：[QUICK_START.zh-CN.md](#) · 安装说明：[INSTALL_WINDOWS.zh-CN.md](#) · 故障排查：[TROUBLESHOOTING.zh-CN.md](#)

macOS 暂无安装包，需从源码运行（系统声音需 BlackHole 虚拟音频设备）：[INSTALL_MACOS.en.md](#)

🖥 单屏 / 双屏

标题栏有一个分段控件 **单屏 | 双屏**，它决定「答案显示在哪里」：

	单屏（原有行为）	双屏
显示	这台电脑的悬浮窗	局域网里的手机浏览器
电脑屏幕	看得见窗口	主窗自动隐藏、强制隐身，共享/录制里什么都拍不到
触发	点转写气泡上的 ⚡ 答	Ctrl+Shift+S 整屏截屏答题 · Ctrl+Alt+A 答最新一句 · Ctrl+Alt+S 框选截屏答题
持续答	自己开	进入双屏时自动打开

点 **双屏** 会立刻弹出一个**连接窗口**：大二维码、可复制的地址、6 位配对码、已配对设备与在线状态。手机扫码 → 输配对码 → 连上后这个窗口自己收起、主窗随之隐藏。之后要再看二维码，点标题栏的 **双屏**（已在双屏时再点一次就是重新呼出），或 **设置 → 通用 → 手机显示 → 打开连接窗口**。

电脑负责听、查本机题库与资料、调 AI；手机只负责给你看。转写与答案都来自主进程的事件源，**不经过界面窗口**，所以窗口隐藏与否不影响手机收到内容。

连接与配对步骤：

1. 手机与电脑连**同一个 Wi-Fi**（手机别开移动数据兜底，否则它会走别的网段）。
2. 电脑点标题栏 **双屏** —— 连接窗口立刻弹出。
3. 手机相机扫那个**二维码**（手动输地址也行，形如 `https://192.168.10.23:18765/`）。
4. 手机上点「请求配对」后，**回到连接窗口看 6 位配对码**（配对码不会显示在手机上），输进手机即可。之后令牌存在手机本地，重开页面直接连。
5. 手机上点一次「**常亮**」（浏览器要求必须由你点一下才允许保持亮屏）。
6. 电脑上点 ▶ **开始**，转写与答案就会持续推送到手机。
7. 想在**完全不看电脑**的情况下截屏答题：在连接窗口里勾选「**截屏热键只送手机**」，然后按 `Ctrl+Shift+S` 或 `Ctrl+Alt+S`（勾选后两者行为相同：都整屏抓取、答案直送手机，电脑这边不弹任何窗口）—— 拍屏、读题、**先查本机题库**、答案直接出在手机。不勾选时 `Ctrl+Alt+S` 恢复常规行为：弹出做题小窗、等你拖框选题目区域。读题这一步需要**视觉模型**或本地 OCR：两者都没有时，链路会直接告诉你缺哪一个，而不是默默给你一个空答案。用 DeepSeek 的话，视觉模型选 **DeepSeek 视觉·flash** 即可与文本共用同一个 Key（设置 → 视觉模型）。

连不上时的排查顺序：① Windows 第一次监听会弹防火墙提示，必须点「允许」并勾选**专用网络**（拒绝之后的表现是手机永远连不上、电脑侧毫无异常）；② 确认手机和电脑在同一网段；③ 连接窗如果显示「未监听」，看它旁边给出的原因（多半是端口被占用）；④ 手机报证书错误时**分清是哪一种**：
`ERR_CERT_AUTHORITY_INVALID` 点「高级 → 继续前往」即可；若报的是 `ERR_CERT_INVALID`，那是**硬拦、没有任何绕过入口**，直接点连接窗里的「**改用 HTTP**」；⑤ 若地址是 `http://` 而手机浏览器仍报 `ERR_PROTOCOL_ERROR`，是浏览器把地址自动升级成了 `https`—— 请完整输入 `http://` 前缀，或关掉浏览器的「始终使用安全连接」。

隐私边界：这条链路只在你**主动开启**后才监听端口；数据只在电脑与手机之间直连，不经过任何第三方 服务器；关掉开关即停止监听。默认端口 **18765**。

在手机上实时改设置（双屏进行中的控制）

连上之后手机页面顶部多出一条 **控制** 栏：折起来是一行状态（转录 / 连续回答 / 内容量·专业度 / 当前会话与已答条数），点开就是控件。会议进行中不用回头碰电脑就能改的东西全在这里：

控件	对应桌面开关	说明
转录 开始 / 停止	► 开始	远程开转录优先走桌面原生采集；走不通时表现为「一直未确认」（见下）
连续回答 开 / 关	⚡ 连续答	同一个真开关，不是手机侧的本地状态
内容量 精简 / 标准 / 详尽	提词卡「回答风格」	下一句回答立即生效，无需重连
专业度 口语 / 职场 / 技术	同上	同上
输入问题 + 发送	自由提问	手机上 只有文本提问 ；回答沿用同一条答案流，出现在手机顶部
历史回答	回答栏历史	本次会话的全部已答条目，手机上回看、点一下重新铺满

三条使用须知：

- **颜色就是桌面的真实状态**：转录红 = 桌面正在转录，连续绿 = 连续答已开，蓝 = 当前档位。关掉的那一项只是中性描边——绿色的「关」按钮是骗人的。
- **点下去不等于生效**：待确认时按钮是黄色描边加省略号，1.5 秒内电脑把新状态推回来才算数，否则标成「未确认」并把按钮还给你。**电脑上不会弹任何提示**——远程控制的意义就是不打断你正在共享的屏幕。
- 因此「转录未确认」通常不是坏了：Windows 上浏览器采集需要你**真实点一下页面**才允许录音，没有原生产物时也只能走这条路。要稳，还是在电脑上点 **► 开始**。

权限在 **设置 → 通用 → 手机显示**：**允许手机远程控制** 是总开关（**默认开启**，因为能让它连上的设备本来就是你手里那台刚输过 6 位配对码的），关掉后手机上整块控制区直接不出现；下面六个**逐项授权**可单独收掉某一类，被收掉的项是从手机页面上**移除**而不是变灰。只想给看、不想给改，就把总开关关掉——推送内容那一栏（转写 / 答案 / 截图）与控制权限是两套独立的开关。

本地语音识别（可选，免云端）

应用**自动拉起并回收**本地 sidecar 进程，你只需在设置里选好方案，模型首次运行自动下载。

FunASR（默认本地方案）

Python 3.10 conda 环境 + `funasr` + `torch`（NVIDIA GPU 推荐）：

```
conda create -n funasr python=3.10 -y
conda activate funasr
pip install "torch==2.11.0" --index-url https://download.pytorch.org/whl/cu128 # 按你的 GPU 选
```

```
择
pip install -r requirements-funasr.txt
```

模型（paraformer ≈880MB / Nano ≈1.7GB）首次运行自动从 ModelScope 下载。解释器查找顺序：
MC_FUNASR_PYTHON → 项目 .venv → C:\ProgramData\miniconda3\envs\funasr → python（PATH）。

MOSS-Transcribe-Diarize 0.9B（实验）

隔离的 Python 3.12 环境，避免 Transformers 5.x 干扰 FunASR：

```
conda create -n moss-asr python=3.12 -y
conda run -n moss-asr python -m pip install torch==2.11.0 --index-url
https://download.pytorch.org/whl/cu128
conda run -n moss-asr python -m pip install -r requirements-moss.txt
```

首次运行从 Hugging Face 下载约 1.7GB BF16 权重，设备顺序 CUDA BF16 → CPU。可用 MC_MOSS_PYTHON / MC_MOSS_DEVICE 覆盖解释器与设备。注意 MOSS 非流式模型，按约 700ms 静音分段整句返回。

Whisper turbo（离线兜底）

把 onnx-community/whisper-large-v3-turbo-ONNX 放入 %APPDATA%\MeetingAssistant\models\onnx-community\whisper-large-v3-turbo-ONNX/，编码器走 DirectML GPU。

完整平台配置见 docs/windows/SETUP.zh-CN.md（Windows）与 docs/macos/SETUP.md（macOS）。

✂ 从源码开发

环境要求

组件	要求
系统	Windows 10 / 11（64 位）； macOS 14+（Apple silicon）
运行时	Node.js ≥ 20 与 npm
LLM Key	任意 OpenAI 兼容 API Key（推荐 DeepSeek）

安装与运行

```
git clone https://github.com/lakaka2970/MeetingAssistant-main.git
cd MeetingAssistant-main
start.bat          # Windows 一键启动：首次运行自动自检并装配环境，或手动 npm install && npm
start
```

Windows 下双击 `start.bat` 即可，不必先手动执行安装与构建：它会依次自检 Node.js ≥ 20 （缺失时给出安装指引）、安装 npm 依赖（默认源失败时自动写入 `.npmrc` 国内镜像并重试一次）、校验 transformers.js 补丁、补下载 Electron 二进制（失败自动改用镜像）、构建，最后启动应用；本地 ASR / OCR / 原生音频等可选能力只做提示，不阻塞启动。逻辑在 `tools/start-check.ps1`（`start.bat` 只是纯 ASCII 壳，cmd 对 UTF-8 批处理会截行）。

cn npm / Electron 下载慢时，在项目根目录建 `.npmrc`：`registry=https://registry.npmmirror.com` 与 `electron_mirror=https://npmmirror.com/mirrors/electron/`

常用脚本

命令	作用
<code>npm run dev</code>	开发模式（electron-vite dev，热更新）
<code>npm run build / npm start</code>	构建 / 预览构建产物
<code>npm run typecheck</code>	TypeScript 全量类型检查
<code>npm test / npm run test:python</code>	单元测试 / Python sidecar 测试
<code>npm run verify</code>	类型检查 + 测试 + 构建（提交前推荐）
<code>npm run dist:win</code>	打包 Windows 安装包（NSIS + portable）
<code>npm run smoke:*</code>	各能力冒烟测试（ASR / LLM / RAG / E2E）
<code>npm run smoke:companion</code>	手机显示冒烟：真启动主进程，验证端口监听与页面/脚本/证书/KaTeX 均可取
<code>npm run qa:inventory -- <目录></code>	干跑面试知识库：看某目录能被识别出多少条「准备的答案」
<code>npm run exam:selftest -- <题库目录> [题目...]</code>	干跑做题题库：绑定→配对→检索→给出答案与耗时（不调模型）

可选：原生音频后端 (Rust)

默认 `audio.captureBackend = webaudio`，开箱即用。想要 Windows WASAPI 回环直采（无需虚拟声卡）可构建 `rust/` 下的 `napi-rs` 模块（`cd rust && npm install && npm run build:release`），产物 `resources/native/meeting-assistant-audio.node` 缺失时自动回退 Web Audio 路径。详见 [rust/README.md](#)。

项目结构

<code>electron/</code>	# 主进程：悬浮窗、隐身、快捷键、设置、IPC、ASR/LLM/RAG 宿主、托盘、做题小窗与题库（ <code>electron/exam/</code> ）、局域网手机显示（ <code>electron/companion/</code> ）
<code>src/</code>	# 渲染进程（React）：转录面板、回答会话、知识库、设置、配置向导、做题小窗

```
(src/exam/)
shared/          # 纯数据模块（渲染/主进程共用）：服务商目录、协议、平台、题库解析与检索、人设引擎、判题门控
resources/       # 随包发布的只读载荷：Python sidecar 脚本、托盘图标、内置技能、手机显示页（resources/companion/）
electron/asr/    # 语音识别后端路由（FunASR sidecar / MOSS / 云端 / Whisper）
electron/llm/    # LLM 适配与路由（流式、多模态、失败回退）
electron/rag/    # 简历/JD 索引与检索（本地解析，提问时注入上下文）
tools/           # Python sidecar 服务器与冒烟脚本（funasr_stream_server.py 等）
rust/            # 可选原生音频采集（napi-rs + WASAPI/cpal）
docs/            # 用户文档（快速开始 / API Key / 故障排查 / 平台配置）与截图素材
```

✓ 测试与质量

CI（[.github/workflows/ci.yml](#)）在 Windows 上自动执行：`typecheck` → `npm test` → `test:python` → `build` → `verify:patched`（确认 `transformers.js` 补丁未被依赖安装覆盖）。本地提交前可跑 `npm run verify`。诊断问题：应用内 **设置** → **通用** → **诊断信息**（或标题栏 ... 菜单）生成不含敏感内容的诊断报告（仅复制到剪贴板，不落盘），可随 issue 提交。

文档索引

文档	说明
QUICK_START.zh-CN.md / EN	面向普通用户的五步快速开始
API_KEYS.zh-CN.md / EN	各服务商 Key 领取教程
README.pdf	本文档的 PDF 版（离线分发 / 打印）
TROUBLESHOOTING.zh-CN.md / EN	错误代码表与排查指南
INSTALL_WINDOWS.zh-CN.md / EN	Windows 安装说明（含 SHA256 校验）
INSTALL_MACOS.en.md	macOS 从源码安装与 BlackHole 音频路由
docs/windows/SETUP.md / zh-CN	Windows 平台完整配置（Python / 本地 ASR）
docs/macos/SETUP.md	macOS 平台完整配置
RELEASE_NOTES_v1.0.1.md	当前版本 说明：升级必读的三个默认行为变更、新增内容、已知问题
RELEASE_NOTES_v1.0.0.md	上一版（首个正式版）说明与已知问题

开源许可

Apache License 2.0

English

MeetingAssistant is a real-time meeting / interview assistant for Windows and macOS. It captures the other party through **system loopback audio** (no bot, no integration—works with any meeting app), transcribes it with streaming ASR, and generates **first-person answers you can read aloud**, powered by your own BYOK (bring-your-own-key) LLM provider. It is local-first: the default ASR backend (FunASR) runs on your machine and audio never leaves it unless you configure a cloud provider. A printable/offline copy of this document is available as [README.pdf](#).

Highlights

- Streaming ASR: local FunASR (default), Alibaba Cloud Bailian realtime (recommended cloud), MiMo, experimental MOSS-Transcribe-Diarize, offline Whisper fallback
- Per-line ⚡ Ans answers + 🎙 optional mic channel; text (纯文本) or multimodal/vision mode with screenshot Q&A
- Transcript as chat bubbles: one bubble per sentence, coloured by speaker, wrapping inside the bubble; **copy / translate / ⚡ Ans** appear on hover or keyboard focus instead of sitting there permanently. ↗ opens the full-transcript panel (clicking a bubble no longer does), the rail's edge drags to resize, and the answer history above the prompt card collapses to a single "Answer history · N" row.
- ⓘ **Answer style, switchable mid-meeting:** length (brief / standard / detailed) × register (plain / work / tech) × persona, all from the title bar, applied to the next answer with no restart. Up to 12 saved personas (Settings → General → Advanced → Persona library, one tap drafts a persona from your resume/JD), and an **advanced prompt editor** for the three prompt layers (base persona / style directives / custom appended instructions) with a live assembled-prefix preview. Leaving a layer empty uses the built-in wording, and an untouched install sends **the same bytes** to the model it sent before the upgrade.
- Thinking is off by default: reasoning-capable models no longer bill you in first-token latency and tokens for reasoning you never asked for; pick low/medium/high per preset in Settings → Model if you want it.
- Knowledge panel: import your resume/JD (.md/.txt/.docx/.pdf/.pptx), parsed and indexed locally, only sent to your LLM as context when asking; each session is one interview with its own material
- Batch document import reports itself: Settings → Knowledge takes single files (multi-select) or a whole folder, shows Importing 12/37... while it runs and one row per file — imported / unchanged / skipped / failed — with the reason (unsupported format, no extractable text, parse failed, index not ready). Re-importing an unchanged file is skipped by content hash instead of rebuilding the index, and each imported document is cut into sections whose extractive summaries go into the index for document-level questions — locally, with no model call and no cost.
- Prepared answers surface first: 问: ... 答: ... / Q: ... A: ... / 【问题】...【回答】... blocks in your documents or notes are auto-detected and indexed by question; on a hit the prompt card shows your prepared answer verbatim (local, tens of ms) and the AI only enriches it — no network on that path

- Exam mode (做题模式): a separate small floating window, forcibly invisible to screen capture, for online assessments. Drag over the question on screen → it is read (local OCR first, vision model otherwise) → **your local question bank answers it in ~1 ms, offline**; the LLM only covers what the bank lacks, and the web only on an explicit opt-in. Four sub-modes, each bound to its own folder: aptitude/essay, coding/technical, personality, other. Paired real-exam PDFs (...-学生版.pdf + ...-答案版.pdf , keys like N. 【答案】 D。解析: ... or 1~5 BACDB) are joined by (section, number) and **refuse to pair when the two papers' sections disagree** — a wrong answer with confidence is the one outcome this must never produce; when the OA page shuffles the options, the answer is re-anchored onto the option text and the on-screen letter. Reading the screen needs either `npm i tesseract.js` (offline, tried first) or a vision-capable key; with neither, paste the stem into the bank field and use **Answer this** for the same bank → AI → web chain. Binding one shared parent folder to all four sub-modes is fine — the index is literal, so extra material can only ever surface as a "similar question" to confirm, never as a direct answer.
- Phone display over the LAN (设置 → 手机显示): the machine becomes a local-only web service and a phone browser shows the live transcript plus the current answer in large type — streamed token by token, maths typeset with KaTeX. The bridge taps the ASR/LLM/exam event sources **inside the main process**, not the UI, so the PC side can stay hidden or never open a window at all: nothing on this screen is in a shared capture. It also carries the headless screen-answer path — with 「截屏热键只出答案到手机」 on, one press of the screenshot hotkey captures the screen, reads it, **checks your local question bank first** and puts the answer on the phone without raising a window. Latency is an explicit quantity here, not a vibe: the phone calibrates the two clocks with ping/pong so the milliseconds it prints are real end-to-end cost, and the settings row shows wire latency plus how many frames were dropped because a phone could not keep up. Pairing is a 6-digit code → long-lived token, where **the code is only ever displayed on this machine** and never sent back to the device that asked, so nothing else on the LAN can pair itself. HTTPS with a self-signed cert is the default — it encrypts the LAN hop *and* is the only context where the browser's screen Wake Lock exists, so the phone does not dim mid-meeting. Self-signed stops passive sniffing, not an active man-in-the-middle: trusted networks only. Off unless you enable it; default port 18765.
- Two modes stay apart by construction: exam banks and the personality persona live in their own store and never enter the interview RAG index, so civil-service arithmetic cannot start answering interview questions, or the other way round.
- Continuous answering is now gated: greetings and logistics never cost a model call, only a genuinely ambiguous line gets one tiny classifier request, and any timeout or failure falls back to answering.
- Web search is the fallback, not the default: only a question the knowledge base cannot answer at all reaches your own search key (Tavily / Brave / SerpAPI, off by default), under a hard 2.5 s deadline, and the answer cites what came back
- Journal maths render properly: $\$... \$$, $\$ \$... \$ \$$, $\backslash (... \backslash)$, $\backslash [... \backslash]$ are typeset with KaTeX (space-padded $\$... \$$ included), and ***bold*** , *italic* , `code` and ### headings are rendered instead of shown raw
- Sessions are deletable: 🗑 drops the conversation, its transcript and everything its resume/JD contributed to the index, after a confirmation

- BYOK: keys encrypted on-device; no account system, no servers, no reseller fees
- Stealth mode hides the window from screen share/screenshots (effective on Windows); global hotkey `Ctrl+B` + system tray to bring it back
- 5-step first-run wizard, real connection tests (14 normalized error codes), status chips, local diagnostics, in-app help — bilingual UI (中文 / English)

Operating guide (short version) — the full click-level walkthrough is in the Chinese sections 「界面与操作详解」 / 「单屏 / 双屏」 above; the same docs exist in English under `docs/user/` :

- **Transcribe**: play any audio on the PC → title bar ► **Start**; the rail shows one chat bubble per sentence. Hover (or Tab to) a bubble for **copy** / **translate** / **Ans**; in the rail header opens the full-transcript panel — clicking a bubble no longer expands it. Drag the thin strip on the rail's right edge to resize (10–50%). Optional **Mic** transcribes your own speech on a separate channel.
- **Answer**: click **Ans** on any line; toggle **Auto-answer** for continuous mode (gated), **答:中/答:EN** for answer language, **plain-text/multimodal** to switch to the vision model (screenshot Q&A). switches answer length, register and persona for the next answer; the **Answer history • N** row above the prompt card expands and collapses (collapsed by default, and remembered). deletes the whole session (transcript, indexed resume/JD, prepared answers).
- **Resume/JD**: **Resume** / **JD** on the prompt card import `.md/.txt/.docx/.pdf/.pptx`, parsed and indexed locally. `Q:/A:` blocks surface your prepared answer verbatim before the AI enriches it; web search (Tavily/Brave/SerpAPI, off by default, 2.5 s cap) only fires when the local KB misses.
- **Knowledge documents**: Settings → Knowledge → **Import files...** (multi-select) or **Import folder...** — per-file progress and a per-file verdict with the reason when something did not go in; unchanged files are skipped by content hash, and each document's section summaries are produced locally.
- **Prompts**: Settings → General → Advanced → **Persona library** (up to 12, or draft one from your resume/JD) and **Advanced prompt editor** (the three layers, grey placeholder = built-in wording, empty box = use it, plus the assembled-prefix preview). Thinking effort lives in Settings → Model and defaults to **off**.
- **Exam mode**: title bar **做题** opens a capture-invisible panel bound to per-mode bank folders; drag-select a question (or `Ctrl+Shift+S` full-screen / `Ctrl+Alt+A` last line / `Ctrl+Alt+S` region) → local bank first (~1 ms, offline) → LLM → optional web. See the Chinese section for the four sub-modes and the accuracy rules.
- **Phone display**: title bar **dual-screen** (or Settings → General → Phone display) opens the pairing window — scan the QR, enter the 6-digit code **shown only on the PC**, tap **Keep awake** on the phone. Hotkeys can be set to deliver answers phone-only without raising any window.
- **Remote control from the phone**: once paired, the phone page grows a **控制** bar whose expanded half holds exactly six things — transcript start/stop, continuous answering, answer length and expertise, a text-only question box, and this meeting's answer history. Colours are the desktop's real state (red = capturing, green = continuous); a tap shows a pending outline for 1.5 s and turns into **未确认** if the desktop never reports the value, and **nothing pops up on the desktop** — that is the point. Permissions: **Settings** → **General** → **Phone display** → **Allow remote control** defaults to **on** (a device that got this far was just held in your hand and typed

the 6-digit code shown only here), with six per-item grants underneath; a revoked item disappears from the phone page rather than greying out. Want a screen with no controls at all? Turn the master switch off.

- **Hidden window:** default summon hotkey `Ctrl+B`, or the tray menu (start/stop, new session, settings, service status, help, update check, quit).
- **Latency HUD** (bottom-right): end-to-end speech→caption (last / p50 / p95), first-token and reasoning time — each entry has a hover explanation.

Getting and filling API keys — a key is a credential you create in a provider's console; it is not your password, it spends your money, and it can be revoked any time. You normally need two: one for speech recognition (Alibaba Cloud Bailian, mainland account) and one for AI answers (DeepSeek recommended); MiMo covers both with a single key (Beta); Zhipu GLM-4-Flash offers a generous free tier; Groq is a fast overseas lane; Ollama needs no key at all (local, leave the key field empty, base URL `http://127.0.0.1:11434/v1`). Fill them in **step 3 of the first-run wizard** (each card has a tutorial and an "open key page" button) or under the matching Settings tab (**Speech recognition / Model / Vision & search** — the latter also holds the optional vision-model key, its proxy field, and the web-search fallback keys). Always press "**Save and test connection**": it strips stray quotes/ `Bearer` prefixes, then sends one tiny real request and reports a normalized error code on failure. Keys are encrypted via DPAPI (Windows) / Keychain (macOS), live only in the main process, and the UI only ever shows the last 4 characters. Step-by-step per-provider instructions: [API_KEYS.en.md](#).

Install (Windows): download the NSIS installer or portable `.exe` from the [Releases page](#) and verify the SHA256 sidcar file. macOS: run from source (needs a virtual audio device such as BlackHole) — see [INSTALL_MACOS.en.md](#).

Run from source: `git clone ... && npm install && npm run build && npm start` (Node ≥ 20). Full walkthrough: [QUICK_START.en.md](#). Key guides: [API_KEYS.en.md](#). Troubleshooting: [TROUBLESHOOTING.en.md](#).

Supported providers: DeepSeek, Alibaba Cloud DashScope (CN/INTL), MiMo, Zhipu, Groq, Gemini, Ollama, plus any OpenAI-compatible endpoint — see `shared/providerCatalog.ts` (single source of truth).

License: [Apache-2.0](#). The installers are not code-signed (`v1.0.1`) — download only from this project's Releases page.